

ANÁLISE EXPLORATÓRIA E REGRESSÃO

Homicídios Globais

Uma Análise com Dados da ONU

Fonte: UNODC — United Nations Office on Drugs and Crime

De onde vêm os dados?

UNODC — Crime and Criminal Justice Statistics

O que é: Base de dados oficial da Organização das Nações Unidas sobre homicídios intencionais em todo o mundo.

O que registra: Quantidade de vítimas e taxa por 100 mil habitantes, separadas por país, região, sexo, faixa etária e ano.

Por que usar: É a fonte mais completa e padronizada de dados criminais globais, cobrindo mais de 190 países.

190+

Países cobertos

Década

Série histórica de dados

2 tabelas

Países e Estimativas Regionais ONU

Limpeza e Tratamento dos Dados

① Padronização da Coluna Age

Removidos espaços extras e substituído '60 and older' por '60+' para uniformizar os rótulos de faixa etária.

② Correção dos Valores Numéricos

A coluna VALUE continha vírgulas como separador decimal (ex: '1,5'). Convertida para ponto e depois para tipo numérico com `pd.to_numeric()`.

③ Separação em Dois Datasets


`df_paises`: dados por país (análise própria). `df_onu`: estimativas regionais da ONU. Cada análise usa a base correta.

④ Preservação do Dataset Original

Trabalhamos em uma cópia (`df_tratado = df_unodc.copy()`) para manter o histórico original intacto.

Top 10 Países com Maiores Taxas de Homicídio

Média da taxa por 100 mil habitantes — período 2018 a 2022 (Valores arredondados)



Por que taxa e não contagem?

Países mais populosos teriam vantagem injusta em valores absolutos. A taxa por 100 mil hab. nivela a comparação.

Por que média dos 5 anos?

Evita que um único ano anormal distorça o ranking. A média representa melhor o padrão do período.

Resultado principal

América Latina e Caribe dominam o ranking, com países da América Central no topo.

Homicídios de Mulheres em 2022

Top 10 países + análise de proporção feminina no total de vítimas

Análise 1 — Taxa de Homicídio (Mulheres)

Filtramos por:

- Sexo = Feminino ('Female')
- Indicador = Intentional Homicide
- Unidade: Taxa por 100 mil hab.
- Ano: 2022

Resultado: países onde a mulher tem maior risco proporcional de ser vítima de homicídio, independente do tamanho da população.

Análise 2 — Proporção Feminina no Total

Indo além:

Calculamos a % de vítimas femininas no total de homicídios do país.


Isso responde:

- O país tem muitos homicídios no geral?
- Ou as mulheres são alvos desproporcionais?

Importante: para proporções usamos Counts (valores absolutos), não taxas — pois taxas não podem ser somadas diretamente.

Quais Regiões Concentram Mais Homicídios?

Total acumulado histórico de vítimas por grande região geográfica



Por que Counts aqui?

A pergunta é 'onde ocorrem mais homicídios fisicamente'. Isso requer contagem direta, não taxa proporcional.

Agrupamento por Região

Usamos `.groupby('Region')` no `df_países` para somar todos os países de cada continente de forma controlada.

Destaque

As Américas lideram o volume total, refletindo a alta violência na América Latina e Caribe.

Países com Menor Número de Homicídios por Sub-região

Comparando duas abordagens: soma bruta versus média anual

⚠ Método 1 — Soma Total (Problemático)

Agrupa por sub-região + país e soma todos os anos.

Problema: um país que reportou dados por apenas 1 ano terá total menor do que um microestado seguro que reportou 20 anos consecutivos.

Resultado: ranking distorcido por inconsistência nos dados históricos.

✓ Método 2 — Média Anual (Correto)

Calcula a média de homicídios por ano para cada país.

Vantagem: nivelar o número de anos reportados por cada país, tornando a comparação justa.

Usamos `.idxmin()` para encontrar o índice do menor valor em cada sub-região de forma eficiente, depois `.loc[]` para recuperar os dados completos.

Países com Menor Mortalidade Feminina

Identificando os países mais seguros para mulheres com a métrica correta

⚠ Armadilha estatística com valores absolutos

Microestados (Mônaco, San Marino...) sempre aparecem no topo com valores absolutos baixíssimos — não por serem mais seguros, mas por ter pouquíssimas mulheres.

01

Uso de taxa proporcional

Trocar Counts por 'Rate per 100,000 population' elimina o viés demográfico e compara o risco real de uma mulher ser vítima.

02

Calcula a média histórica

Média das taxas ao longo dos anos nivela a cobertura desigual de dados: países com poucos anos reportados não levam vantagem.

03

Resultado confiável

Com taxa média, o ranking reflete países onde o risco proporcional é genuinamente baixo — independente de tamanho populacional ou cobertura histórica.

Decisões Metodológicas do Projeto

Counts ou Taxa?

Taxa por 100 mil hab. para comparações entre países. Counts apenas quando calculamos proporções dentro do mesmo contexto.

Soma ou Média?

Média anual sempre que queremos comparar países com históricos de dados de durações diferentes.

df_países ou df_onu?

df_países para análises próprias. df_onu para validar com as estimativas regionais oficiais da ONU.

Cópia dos dados?

Sim. Trabalhamos sempre em cópias para preservar o dataset original e garantir reprodutibilidade.

Por que 2018–2022?

Últimos 5 anos disponíveis com cobertura global razoável. Anos mais recentes têm dados incompletos.

Filtros: Total em Age, Sex, Dimension?

Para evitar dupla contagem ao somar subcategorias que já estão incluídas no agregado 'Total'.

O que é Regressão?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \varepsilon$$

O que faz?

Encontra a relação matemática entre uma variável que queremos prever (y) e outras variáveis explicativas (x).

Para que serve?

Prever valores futuros, entender quais fatores mais influenciam um fenômeno e quantificar esse impacto.

No nosso projeto

Analisamos se variáveis como região e ano conseguem explicar a variação nas taxas de homicídio.

Como avaliamos?

R^2 mede o quanto o modelo explica os dados. Quanto mais próximo de 1, melhor o ajuste do modelo.

Definindo o Escopo: Brasil, 2013–2022

Regressão Linear Simples para prever a tendência de homicídios no Brasil

```
pais_alvo = 'Brazil'

df_filtrado = df[
    (df['Country'] == pais_alvo) &
    (df['Sex'] == 'Total') &
    (df['Year'] >= 2013) &
    (df['Year'] <= 2022)
]
```

Por que o Brasil?

País com alto volume de dados históricos e relevante para análise de tendência de violência na América Latina.

Por que 2013–2022?

Janela de 10 anos: suficiente para capturar tendência real sem incluir anos com dados incompletos ou muito antigos.

Variável explicativa (X) e variável alvo (y)

X = Year (ano) → variável explicativa: o tempo é o único preditor do modelo

y = VALUE (contagem de homicídios) → o que queremos prever

Regressão Linear Simples: $y = \beta_0 + \beta_1 \times \text{Ano} + \varepsilon$

Tratamento dos Dados para Regressão

Três decisões essenciais antes de treinar o modelo

01

Agrupar por Ano — .max()

Por que .max() e não .sum() ou .mean()? O dataset tem múltiplas linhas por ano (por dimensão, categoria, mecanismo). Somar duplicaria os valores. O máximo captura o maior valor agregado reportado para aquele ano — o dado mais representativo do total.

```
df_agrupado = df_filtrado
                .groupby('Year')['VALUE']
                .max().reset_index()
```

02

Tratar Zeros — .replace(0, NaN)

Valor zero em homicídios não significa ausência de crime — significa dado não reportado ou erro na coleta. Incluir zeros no treino distorceria a linha de regressão, puxando a tendência artificialmente para baixo.

```
df_agrupado['VALUE'] =
df_agrupado['VALUE']
                .replace(0, np.nan)
```

03


Preencher Lacunas — .interpolate()

Após substituir zeros por NaN, usamos interpolação linear para estimar o valor faltante com base nos anos vizinhos. Isso preserva a continuidade da série temporal sem remover linhas — essencial quando temos poucos pontos (10 anos).

```
df_agrupado['VALUE'] =
df_agrupado['VALUE']
                .interpolate()
```

Treinamento do Modelo

LinearRegression do scikit-learn — $X = \text{Ano}$, $y = \text{Contagem de homicídios}$



Como treinar

```
modelo = LinearRegression()  
modelo.fit(X, y)
```

O modelo ajusta β_0 e β_1 minimizando o erro quadrático total entre os valores reais e os previstos.

Métrica: MSE


Mean Squared Error — Erro Quadrático Médio.

```
mse = mean_squared_error(y, previsoes)
```

Mede o quanto as previsões do modelo se distanciam dos valores reais. Quanto menor, melhor.

Previsões para 2023–2026

Extrapolando a tendência histórica para os próximos anos



```
anos_futuros = [2023,2024,  
                2025,2026]
```

```
dados = pd.DataFrame(  
    {'Year': anos_futuros})
```

```
previsoes = modelo.predict(  
    dados)
```

Como funciona o .predict()?

O modelo aplica a equação aprendida ($\beta_0 + \beta_1 \times \text{Ano}$) sobre os anos futuros. Cada ano gera uma previsão de homicídios.

Limitação importante

A regressão linear assume que a tendência passada continuará. Eventos externos (políticas, crises) podem quebrar essa tendência.

Configuração do Modelo Preditivo

Prevendo o número de homicídios no Brasil com base no histórico de 2013 a 2022

Definições da análise

País analisado: **Brasil (Brazil)**

Período: **2013 a 2022 (10 anos)**

Variável alvo (y): **VALUE — nº de homicídios**

Variável preditora (X): **Year — ano do registro**

Filtro de sexo: **Total (homens + mulheres)**

Tipo de modelo: **Regressão Linear Simples**

Por que o Brasil?

O Brasil está entre os países com maiores taxas de homicídio do mundo, com dados históricos consistentes reportados à ONU — ideal para treinar um modelo preditivo.

Por que Year como X?

O ano captura a tendência temporal dos homicídios. A regressão identifica se os números estão crescendo, caindo ou estáveis ao longo do tempo.

Por que Regressão Linear?

Modelo interpretável e direto. Com apenas uma variável preditora (Year), a regressão linear é suficiente para capturar a tendência histórica e gerar previsões futuras.

Tratamento dos Dados e Treinamento

Decisões técnicas tomadas antes de treinar o modelo

01

Agrupamento por Ano

```
groupby('Year')['VALUE'].max()
```

Agrupamos os dados por ano e extraímos o valor MÁXIMO. Isso captura o pico real de homicídios registrado em cada ano, evitando que subcategorias sobrepostas reduzam artificialmente o valor.

02

Tratamento de Zeros

```
replace(0, np.nan) → interpolate()
```

Anos com valor 0 indicam dado ausente ou falha no reporte — não que não houve homicídios. Substituímos por NaN e usamos interpolação linear para estimar o valor esperado com base nos anos vizinhos.

03

Treinamento do Modelo

```
LinearRegression().fit(X, y)
```

X = coluna Year (variável preditora)
y = coluna VALUE (número de homicídios)

O modelo ajusta uma reta aos dados históricos, encontrando a relação linear entre o ano e o número de homicídios.

04


Avaliação com MSE

```
mean_squared_error(y, previsoes_treino)
```

O MSE (Erro Quadrático Médio) mede o quanto as previsões do modelo diferem dos valores reais. Quanto menor o MSE, mais preciso o ajuste da reta aos dados históricos.

Previsões para 2023–2026

O modelo treinado projeta a tendência histórica do Brasil para anos futuros



Saída do modelo

Ano 2023

→ `modelo.predict([[2023]])`

Ano 2024

→ `modelo.predict([[2024]])`

Ano 2025

→ `modelo.predict([[2025]])`

Como interpretar?

Cada previsão é o ponto na reta ajustada pelo modelo para aquele ano. A tendência histórica é extrapolada de forma linear.

Conclusões

- 1 América Latina concentra os países com maiores taxas de homicídio
- 2 Taxas proporcionais são a métrica correta para comparar países entre si
- 3 Médias anuais evitam distorções por cobertura histórica desigual
- 4 Regressão Linear capturou a tendência histórica de homicídios no Brasil
- 5 O modelo gerou previsões para 2023–2026 com base em 10 anos de dados
- 6 Dados abertos da ONU possibilitam análises globais completas com Python